



FILTRATGE COL·LABORATIU: PERSONALITZACIÓ I RECOMANACIÓ DE DADES

Pràctica 2 SIO 20025

S'ha assolit el MAE més baix del projecte: 3,131

Nawfal Aissaoui, Salma Jadiani

ÍNDEX:

- 1. Filtratge col·laboratiu.**
- 2. Anàlisi del dataset i implicació algorítmica.**
 - a. Dimensions i estructura.**
 - b. Densitat de dades.**
 - c. Distribució de valors i escala.**
- 3. Mesures de similitud:**
 - a. Matriu de residus.**
 - b. Pearson sobre residus.**
 - c. Similitud coseno.**
- 4. Tècniques i algoritmes utilitzats.**
 - a. Algoritmes baseline.**
 - b. Algoritmes basats en la memòria- KNN.**
 - c. Algoritmes basats en la contracció -shrinkage.**
 - d. Algoritmes basats en models -SVD.**
- 5. Conclusions i gràfica comparativa MAE.**

1. Filtratge col·laboratiu.

El filtratge col·laboratiu és una tècnica utilitzada en els sistemes de recomanació que permet predir les preferències d'un usuari a partir d'un anàlisi de patrons de comportament d'un grup d'usuaris. La idea en que es basa és que si dos usuaris van estar d'acord en el passat, es pot assumir que tenen els mateixos gustos i, per tant, es pot predir que estaran d'acord en un futur.

Hi ha dos tipus principals de filtratge:

- **User-Based:** Es busquen “veïns”. Si a dos usuaris els agraden les mateixes series, quan una nova li agradi a l'usuari A s'assumeix que també agradarà a l'usuari B. Es comparen els usuaris.
- **Item-Based:** Aquí es busca una relació entre els productes. Es busquen patrons globals que segueixen els usuaris al classificar els ítems. Per exemple Si un usuari va anar al restaurant A, el sistema li recomana el B perquè històricament tenen una alta correlació d'assistència. Es comparen els productes.

El filtratge User-Based tendeix a ser més lent degut a que l'escenari comú es que hi hagi més usuaris que ítems. Així doncs, per una banda Amazon sol representar el filtratge Item-Based (milions d'usuaris) i Netflix i Spotify es relacionen amb el filtratge User-Based tot i que en realitat ambdós utilitzen sistemes híbrids.

Aquests models híbrids són clau per resoldre el **Cold Start** (la manca de dades inicials en usuaris nous). Actualment, plataformes com TikTok apliquen variants de **filtratge ultraràpides** que, analitzant la interacció a l'instant en lloc de l'historial llarg, permeten personalitzar el contingut en qüestió de segons.

2. Anàlisi del Dataset.

```
=== DATASET PRINCIPAL ===  
Dimensiones: (73421, 100) (usuarios x restaurantes)  
  
=== ESTADÍSTICAS BÁSICAS ===  
Media global: 0.7419  
Densidad de datos: 55.79%  
Valoraciones por usuario (media): 55.8  
Usuarios sin valoraciones: 0  
Restaurantes sin valoraciones: 0
```

Il·lustració 1 Resum dataset, output de la casella 1.

Abans d'aplicar els algorismes de filtratge, és crucial entendre la topologia de les dades amb les quals es treballa, ja que aquesta condiciona directament l'estratègia computacional.

a) Dimensions i Estructura

La matriu d'interaccions és 73.421 usuaris per tan sols 100 restaurants.

- Implicació algorítmica: Aquesta desproporció suggereix d'entrada que els models Item-Based seran més ràpids de calcular. La matriu de similitud entre ítems serà de mida 100x100, a diferència dels 73kX73k de la matriu d'usuaris.

b) Densitat de Dades (Sparsity)

A diferència dels datasets comercials típics (com Netflix o Amazon, que solen tenir una densitat < 1%), aquest dataset és dens, amb un 55,79% de dades plenes. Així doncs, cada es pot afirmar que (en mitjana) cada usuari ha puntuat 56 restaurants dels 100 disponibles. A més, el Cold Start inicial serà nul degut a que no hi ha usuaris ni restaurants sense valoracions.

- Implicació algorítmica: Com no hi ha *Cold Start*, s'afavoreix directament els mètodes basats en memòria (KNN). Això és perquè al disposar de més de la meitat de la matriu plena amb dades reals, els algorismes de veïnatge poden calcular similituds robustes basades en interaccions explícites, sense necessitat fer estimacions artificials que requereixen els models de factorització per omplir buits

c) Distribució de Valors i Escala

L'anàlisi de les files del dataset revela una escala de valoració de -10 a +10 i, el més important, un biaix d'Usuari (User Bias) extremadament marcat. Les dades mostren clarament que cada usuari té el seu propi "punt de referència", la qual cosa invalida les comparacions directes de notes brutes.

- Usuari: Optimista, Pessimista o polaritzat?

Analitzant manualment les primeres 10 línies del dataset es detecten els següents 3 perfils. Per una banda l'optimista, User3, puntua sistemàticament alt i les seves valoracions son positives i altes: 9.03, 9.27, 7.33, 8.25. Per l'altra banda, en l'User6 s'identifica una personalitat més crítica, ja que la majoria de les seves puntuacions són negatives: -6.17, -8.5, -9.27. I per acabar es veu com l'User1 mostra un comportament bipolar, del -9,85 al 8,79 en les seves valoracions.

Així doncs, s'arriba a la conclusió que un 5 representa un valor completament diferent per cada un d'aquests perfils. Per l'optimista aquest restaurant seria dolent, pel pessimista podria representar el millor sopar mentre que pel bipolar, posar un 5 ni tan sols seria una opció.

- Implicació algorítmica:

No es poden comparar aquests usuaris en brut i per tant és imprescindible aplicar Normalització, per netejar l'exigència de l'usuari restant a cada avaluació la mitjana de l'usuari que l'ha fet.

3. Mesures de similitud.

El càlcul de la similitud entre elements (usuari o productes) és fonamental en molts algoritmes de filtratge col·laboratiu. A continuació, es detallen les tècniques utilitzades per mesurar la similitud en la nostra matriu de residus:

a. Matriu de residus.

La matriu de residus és una representació de les diferències entre les valoracions observades (reals) i les valoracions predites per un model. Aquesta matriu es construeix restant les valoracions predites a les valoracions reals. Per crear la matriu de residus, es normalitza la matriu original de manera que la mitjana de cada usuari es resta de les seves valoracions, així com la mitjana de cada element (producte, restaurant, etc.).

b. Pearson sobre residus.

El coeficient de correlació de Pearson és una mesura de la similitud lineal entre dues variables. En el context del filtratge col·laboratiu, calculem la correlació entre els residus de diferents usuaris o elements per determinar quins són més similars. La fórmula per al coeficient de correlació de Pearson entre dos vectors x i y és:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

On $\bar{x}$ i $\bar{y}$ són les mitjanes dels vectors x i y , respectivament. Aquest mètode es fa servir quan volem mesurar la similitud entre usuaris o elements basant-nos en les seves valoracions centrades.

c. Similitud coseno.

La similitud coseno és una mesura de la similitud entre dos vectors de les matrius de residus. Aquest mètode és especialment útil quan els vectors són esparsos i pot donar bons resultats en sistemes de recomanació. La fórmula per calcular la similitud coseno entre dos vectors A i B és:

$$\text{coseno}(A, B) = \frac{A \cdot B}{\|A\| \|B\|}$$

On:

- $A \cdot B$ és el producte escalar de A i B ,
- $\|A\|$ i $\|B\|$ són les normes (magnituds) dels vectors A i B , respectivament.

Aquesta mesura és ideal per quan volem mesurar la similitud entre elements basant-nos en el valor relatiu de les seves valoracions. I resulta especialment útil quan la densitat de les dades és baixa.

4. Tècniques i algoritmes utilitzats.

Tot comença amb una estructura de dades fonamental: la matriu de preferències.

- Les files representen els Usuaris.
- Les columnes representen els Ítems (restaurants).
- Els valors són les interaccions (puntuacions del -10 al 10).

El repte principal és que aquesta matriu és Dispersa (Sparse): hi ha forats buits perquè cap usuari ha valorat tots els restaurants.

Així doncs, l'objectiu dels algoritmes és predir els valors d'aquests "forats", indicats com a 99 en aquesta pràctica.

1. Algoritmes Baseline.

Es tracta de mètodes senzills que serveixen com a punt de referència per avaluar models més complexos. Es tracta de models bàsics que no tenen en compte les relacions complexes entre els usuaris i els ítems; es fan les prediccions utilitzant estadístiques globals del conjunt de dades.

Serveixen com a punt de partida per a models més complexos ja que redueixen els errors sistemàtics causats pels usuaris o ítems tenint un cost computacional baix.

1.1 Imputació per mitjana global: S'omplen els valors desconeguts amb la mitjana de totes les notes existents a la matriu. És el model més simple possible.

```
=== MÉTODO 1: IMPUTACIÓN POR MEDIA GLOBAL ===
Target cargado: 40000 filas
Media global usada para predecir: 0.7418716494644033
Archivo generado: resultats_global.csv
MAE (cálculo local): 4.429968

Ejecutando compute_mae.py ...
MAE: 4.43

=== FIN MÉTODO 1 (MEDIA GLOBAL) ===
```

1.2 Imputació per mitjana d'usuari o ítem: Es personalitza lleugerament assignant la nota mitjana que sol posar l'usuari o la nota mitjana que rep el restaurant.

1) **Mitjana usuari:** (costós)

```
=== MÉTODO 2: IMPUTACIÓN POR MEDIA DE USUARIO ===
Target cargado: 40000 filas
Archivo generado: resultats_user_mean.csv
MAE (cálculo local): 3.750033

Ejecutando compute_mae.py ...
MAE: 3.75

=== FIN MÉTODO 2 (MEDIA POR USUARIO) ===
```

2) **Mitjana ítem:**

```
=== MÉTODO 3: IMPUTACIÓN POR MEDIA DE ÍTEM ===
Target cargado: 40000 filas
Archivo generado: resultats_item_mean.csv
MAE (cálculo local): 4.173192

Ejecutando compute_mae.py ...
MAE: 4.173

=== FIN MÉTODO 3 (MEDIA POR ÍTEM) ===
```

1.3 Baseline combinat:

Prediu les valoracions utilitzant la mitjana d'usuari i la mitjana d'item ajustades per la mitjana global. S'aplica clipping per respectar el rang de notes.

Predicció = mitjana usuari + mitjana restaurant - mitjana_global

```
=== MÉTODO 4: BASELINE COMBINADO ===  
Prediciendo 40000 valores...  
Archivo generado: resultats_baseline.csv  
MAE (Cálculo local): 3.473153
```

```
Ejecutando compute_mae.py ...  
MAE: 3.473
```

2. Filtratge Col·laboratiu Basat en Memòria (KNN)

El nucli del document se centra en els algorismes k-Nearest Neighbors (k-NN). Es tracta de trobar els k veïns més similars per fer una mitjana ponderada.

2.1 Mesura de Similitud: Correlació de Pearson

En tots els mètodes del document (User i Item), s'utilitza la correlació de Pearson. Pearson ignora la magnitud de les notes (si algú puntua alt o baix per defecte) i se centra en la *tendència* (si les notes pugen i baixen juntes).

2.2 User-Based vs. Item-Based

- User-Based :

```
=== MÉTODO 5: FILTRADO COLABORATIVO (KNN USUARIOS) ===  
Calculando matriz de similitud (esto puede tardar)...  
Matriz de similitud calculada: (73421, 73421)  
Generando predicciones (iterando filas)...  
Procesado: 0/40000 (0%)  
Procesado: 4000/40000 (10%)  
Procesado: 8000/40000 (20%)  
Procesado: 12000/40000 (30%)  
Procesado: 16000/40000 (40%)  
Procesado: 20000/40000 (50%)  
Procesado: 24000/40000 (60%)  
Procesado: 28000/40000 (70%)  
Procesado: 32000/40000 (80%)  
Procesado: 36000/40000 (90%)  
Terminado en 1941.3 segundos.  
MAE (KNN User-Based): 3.370651  
MAE: 3.371
```

- **Item-Based :**

```
=== MÉTODO 5: KNN BASADO EN ÍTEMS ===  
Calculando similitud entre restaurantes...  
Matriz de items calculada: (100, 100)  
Generando predicciones...  
Progreso: 0/40000  
Progreso: 8000/40000  
Progreso: 16000/40000  
Progreso: 24000/40000  
Progreso: 32000/40000  
¡Hecho! Tiempo total: 84.8s  
MAE (KNN Item-Based): 3.195397  
MAE: 3.195
```

2.3 Tècniques de Millora Implementades

Amb intenció de millorar la precisió (MAE), s'han provat els següents mètodes sobre el knn item-based:

1. Normalització Centrada en l'Usuari

Al Mètode 7, abans de calcular res, es resta la mitjana de l'usuari a les seves notes. Això converteix les notes en "preferències relatives" (m'agrada més o menys que la meua mitjana), eliminant així el problema dels usuaris que sempre puntuen alt o baix.

```
=== MÉTODO 7: KNN ITEM-BASED CON NORMALIZACIÓN DE USUARIO ===  
Calculando perfil de usuarios...  
Calculando similitud entre restaurantes (Pearson)...  
Indexando historial normalizado...  
Generando predicciones...  
Archivo generado: resultats_knn_user_centered.csv  
-----  
Tiempo total: 15.77 s  
=== MAE : 3.2085 ===  
-----
```

2. Doble Normalització:

Vegis en el mètode 8 aquesta tècnica que neteja la matriu de tots els efectes externs abans de buscar similituds. L'objectiu és aplicar l'algoritme sobre la "interacció pura", sense estar contaminat per la popularitat del restaurant o l'exigència de l'usuari.

```
=== MÉTODO 8: KNN (k=10) CON DOBLE NORMALIZACIÓN (Correlación de Pearson) ===  
Calculando sesgos globales...  
Aplicando doble normalización a la matriz...  
Matriz purificada. Calculando similitudes...  
Generando predicciones...  
Archivo generado: resultats_knn_double_norm.csv
```

```
Ejecutando compute_mae.py ...  
MAE: 3.136
```

```
=== MÉTODO 8: KNN (k=14) CON DOBLE NORMALIZACIÓN (Similitud del coseno) ===  
Calculando sesgos globales...  
Aplicando doble normalización a la matriz...  
Calculando similitud coseno sobre la matriz normalizada...  
Generando predicciones...  
Archivo generado: resultats_knn_double_norm_cosine.csv
```

```
Ejecutando compute_mae.py ...  
MAE: 3.131
```

3. Shrinkage (Contracció):

Implementat al Mètode 9, és una tècnica de regularització. Penalitza les correlacions o mitjanes que es basen en molt poques dades.

```
*** === MÉTODO 9: KNN ITEM-BASED CON SHRINKAGE y COSENO ===  
Calculando sesgos globales...  
Aplicando shrinkage sobre la matriz de residuo...  
Calculando similitud coseno sobre la matriz de residuo con shrinkage...  
Indexando historial normalizado...  
Generando predicciones...  
Archivo generado: resultats_shrinkage_cosine.csv  
MAE local: 3.137514  
Ejecutando compute_mae.py ...  
MAE: 3.138
```

```
=== MÉTODO 9: KNN (k=10) CON SHRINKAGE POR USUARIO Y COSENO ===  
Calculando sesgos globales...  
Aplicando shrinkage sobre la matriz de residuo por usuario...  
Calculando similitud coseno sobre la matriz con shrinkage...  
Indexando historial normalizado...  
Generando predicciones...  
Archivo generado: resultats_shrinkage_coseno_usuario.csv  
Calculando MAE con compute_mae.py ...  
MAE: 3.148
```

```
-----  
Tiempo total: 106.23 s
```

```
=== MÉTODO 10: KNN (k=10) CON DOBLE SHRINKAGE ===
Calculando sesgos globales...
Aplicando doble shrinkage a la matriz...
Matriz purificada por doble shrinkage. Calculando similitudes...
Indexando historial normalizado...
Generando predicciones...
-----
=== RESULTADO DOBLE SHRINKAGE (k=10) ===
MAE: 3.136395
Tiempo total: 429.53 s
-----
```

4. Algoritmes basats en models (SVD)


Al Mètode 10 es fa la Factorització de Matrius utilitzant SVD (Singular Value Decomposition). En lloc de buscar veïns, l'algorisme descompon la matriu d'usuaris-ítems en tres matrius més petites que capturen **factors latents**.

- **Factors Latents** : Al codi proves amb $k=15$ i $k=13$. Aquests factors representen conceptes abstractes (ex: "ambient romàntic", "menjar picant") que el model descobreix sol. Al codi s'usa conjuntament amb la doble normalització.

```
=== MÉTODO 11 : SVD ===
Dimensiones de la matriz: (73421, 100)
Matriz normalizada. Ejecutando SVD...
Matriz de predicciones reconstruida.
Generando predicciones individuales...
Archivo generado: resultats_svd.csv
-----
Tiempo total: 3.69 s
SVD con k = 10
MAE final (SVD k=10): 3.2229
-----
```

```
=== MÉTODO 12: SVD DOBLE NORMALIZADO ===
Dimensiones de la matriz: (73421, 100)
Matriz normalizada (doble centering). Ejecutando SVD...
Matriz de predicciones reconstruida.
Calculando predicciones individuales...
-----
Tiempo total: 4.96 segundos
=== MAE: 3.1859 ===
-----
Archivo de predicciones guardado: resultats_svd_doble_norm.csv
```

5. Conclusions i gràfica comparativa MAE



Després d'analitzar el dataset i comparar diverses estratègies de filtratge col·laboratiu (Baselines, KNN i SVD), s'extreuen les següents conclusions clau sobre el comportament dels algorismes i la naturalesa de les dades:

- Els models Item-Based s'han demostrat molt superiors en rendiment, ja que calcular una matriu de similitud de 100x100 és immediat, mentre que la versió User-Based (matriu de 73kx73k) ha requerit més de 30 minuts de càlcul.
- L'anàlisi inicial ha revelat perfils d'usuaris molt polaritzats. Això ha fet que els algorismes que treballen amb dades brutes tinguin un error elevat. Així doncs les tècniques de normalització han estat un factor clau per reduir el MAE: Baseline combinat (3,47) i la Doble Normalització.
- KNN Item-Based vs User-Based: L'Item-Based sense optimitzar (3,195) ja supera clarament al User-Based (3,371), confirmant que en aquest dataset és més fiable buscar similituds entre restaurants que entre usuaris.
- El Millor Model: La combinació guanyadora ha estat el KNN Item-Based amb Doble Normalització i Similitud del Coseno, assolint el MAE més baix del projecte (3,131). Tot i que el Shrinkage també ha ofert bons resultats (3,136), el cost computacional extra no ha justificat la minúscula millora o pèrdua de precisió respecte a la doble normalització estàndard¹⁰.
- SVD vs KNN Tot i que la descomposició en valors singulars (SVD) és una tècnica molt potent i ràpida (<5 segons), en aquest cas específic no ha aconseguit superar en precisió al millor model KNN. El SVD amb doble normalització s'ha quedat en un MAE de 3,1859, demostrant que, donada l'alta densitat de la matriu, els mètodes basats en memòria (veïnatge directe) capturen millor els matisos de les dades que l'aproximació per factors latents.